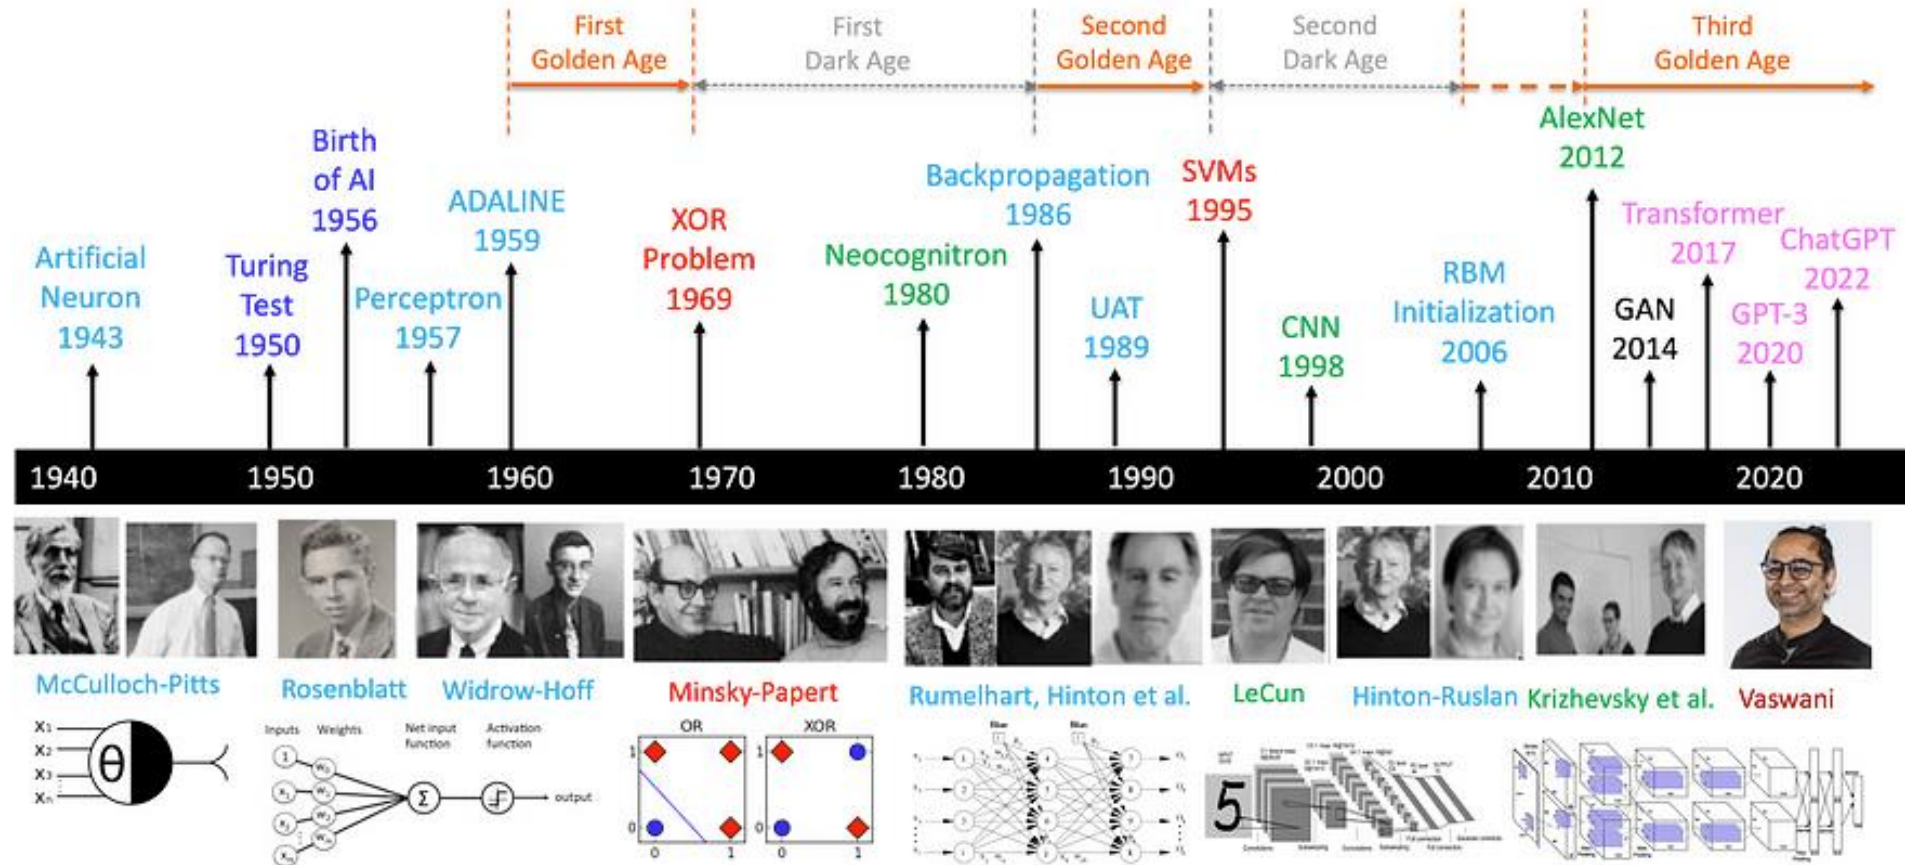


Intro Transformer

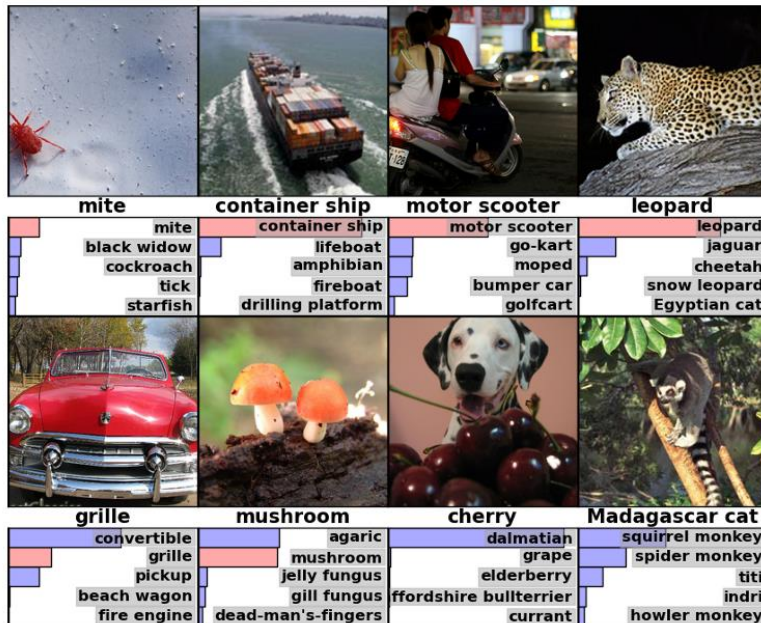
AI History

A Brief History of AI with Deep Learning



AlexNet

Convolutional neural networks running on GPUs (2012) Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton, *Advances in Neural Information Processing Systems 2012*



Deep CNN, ReLU, Dropout



2013. Google acquired DNN

Model	Top-1 (val)	Top-5 (val)	Top-5 (test)
<i>SIFT + FVs [7]</i>	—	—	26.2%
1 CNN	40.7%	18.2%	—
5 CNNs	38.1%	16.4%	16.4%
1 CNN*	39.0%	16.6%	—
7 CNNs*	36.7%	15.4%	15.3%

[ImageNet Classification with Deep Convolutional Neural Networks](#)



Facebook AI Research

Yann LeCun.
Chief AI Scientist for Facebook AI Research (FAIR)

AI divergence

Computer Vision & Learning Group



[Home](#)

[People](#)

[Publications](#)

[Research](#)

[Teaching](#)

[Open Positions](#)

[Prof. Dr. Björn Ommer](#)

[Contact](#)


[University of Munich](#)




Stable Diffusion Developer [Computer Vision & Learning Group \(ommer-lab.com\)](https://ommer-lab.com)

AI Basic Principle

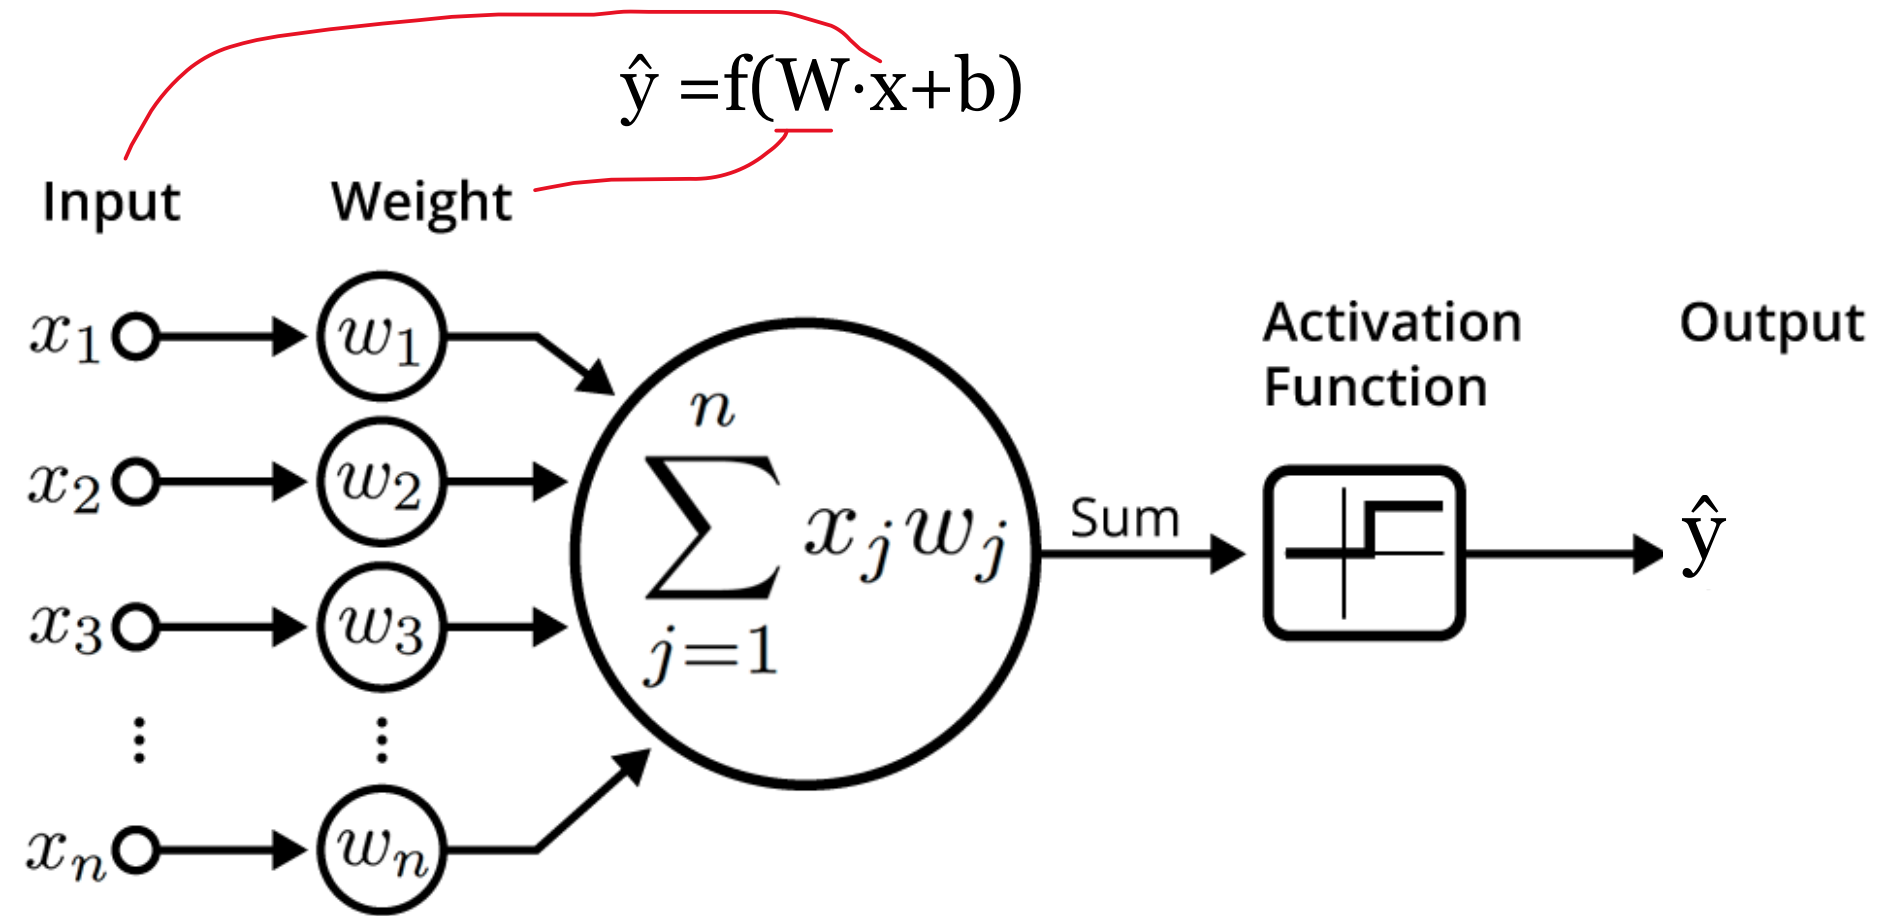
Deep learning



Deep learning

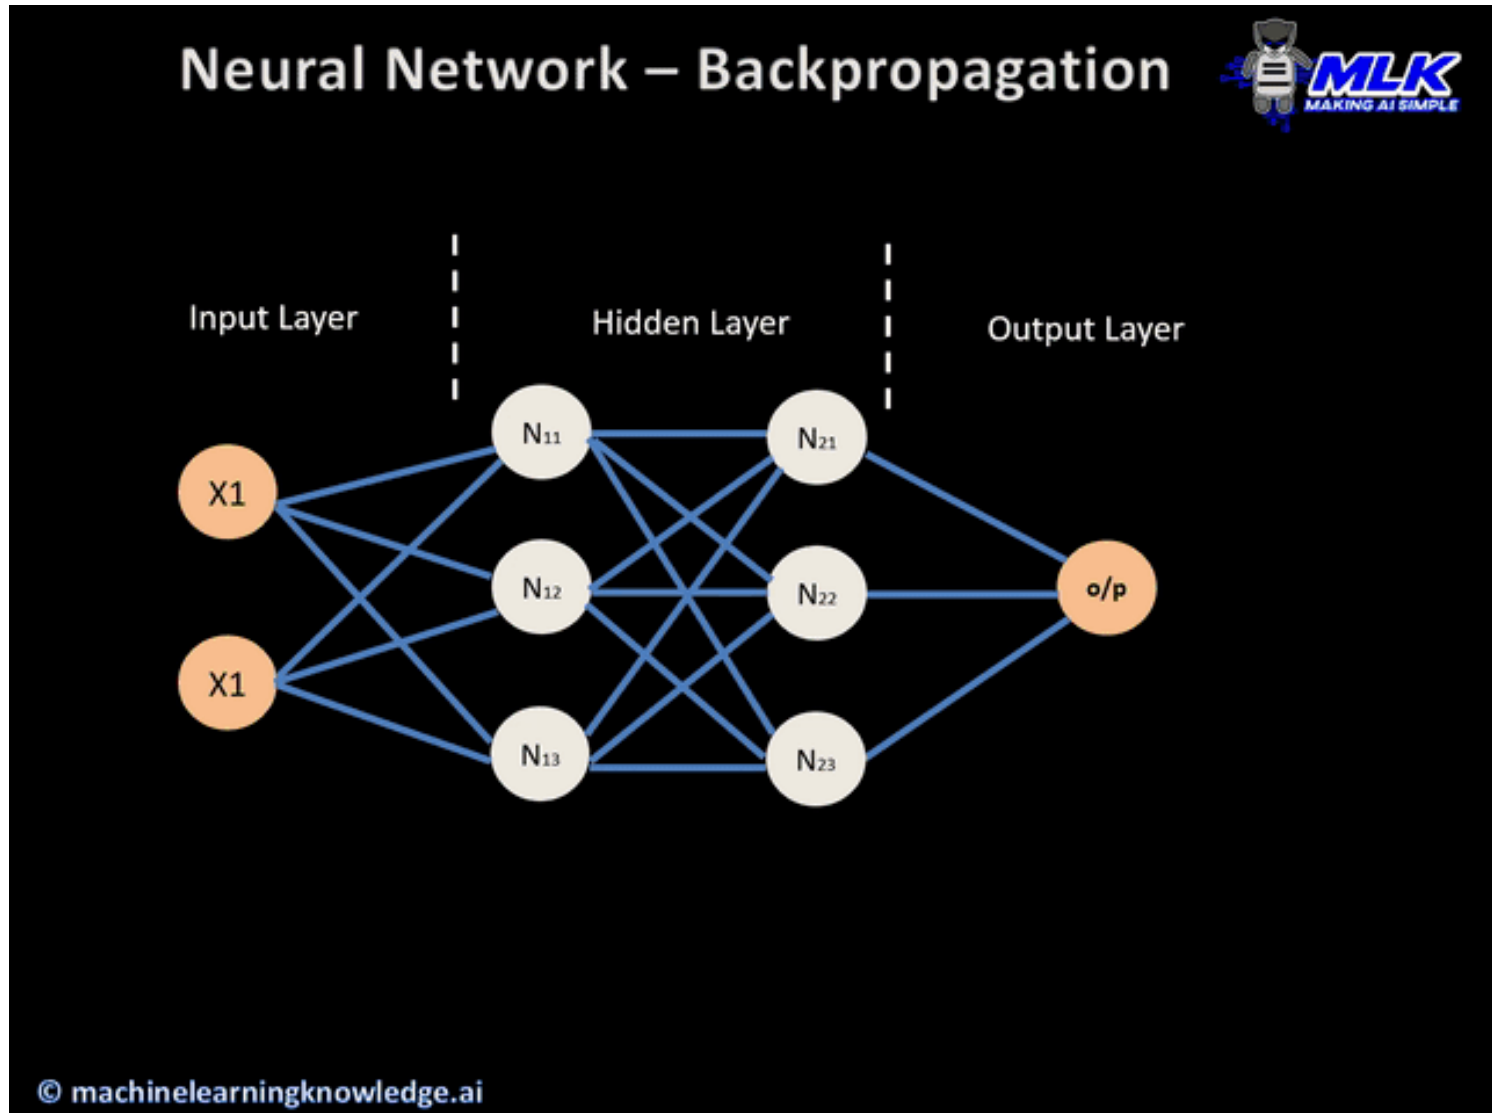


Deep learning



$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2.$$



Deep learning



Deep learning

$$\hat{y} = f(W \cdot x + b)$$


$$\text{target} = \min_{\text{LOSS}}(y - \hat{y}) \quad w_{\text{new}} = w_{\text{old}} + \eta \Delta w$$



Deep learning


$$\hat{y} = f(W \cdot x + b)$$

$$\text{target} = \min_{\text{LOSS}}(y - \hat{y})$$




AI deep learning model network


Model = {target loss fun, differential gradient descent func, input feature, output feature}




● Input Cell
 △ Noisy Input Cell
 ● Hidden Cell
 ○ Probabilistic Hidden Cell
 ● Output Cell
 ○ Match Input Output Cell
 ● Recurrent Cell
 ● Kernel
 ○ Convolution




(a) Neural Network (NN)




(b) Fully-connected Neural Network




(c) Convolutional Neural Network (CNN)




(d) Recurrent Neural Network (RNN)




(e) Auto Encoder (AE)




(f) Sparse AE (SAE)



(g) Denoising AE (DAE)




(h) Variational AE (VAE)




(i) Generative Adversarial Network (GAN)

AI & Deep Learning




$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2.$$

AI & Deep Learning digital numbers




AI & Deep Learning vector




AI & Deep Learning

image = 2D matrix




AI & Deep Learning

image = n-d matrix



AI & Deep Learning token sequence



Transformer

사전, 토큰, 임베딩

딥러닝 모델은 텍스트를 바로 이해하지 못함

문장 → 토큰나이징(tokenizing) → 토큰 ID → 임베딩 벡터

"I am a student" → ["I", "am", "a", "student"]

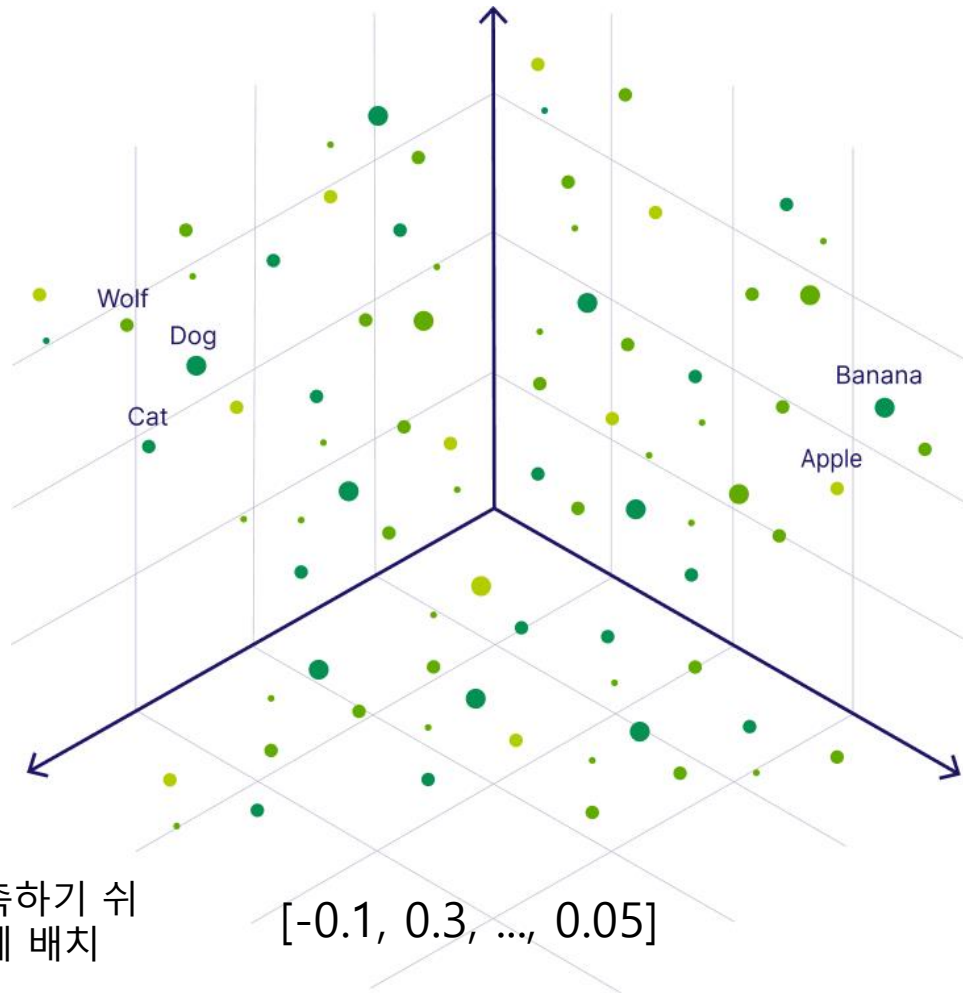
["I", "am", "a", "student"] → [101, 2023, 1037, 3076]

```
embedding = nn.Embedding(vocab_size, d_model)
token_vec = embedding(token_ids)
```

[-0.1, 0.3, ..., 0.05]

사전, 토큰, 임베딩

문장 → 토큰나이징(tokenizing) → 토큰 ID → 임베딩 벡터




```
cos_sim = F.cosine_similarity(embedding("apple"), embedding("banana"))
```

사전, 토큰, 임베딩

문장 → 토큰나이징(tokenizing) → 토큰 ID → 임베딩 벡터

Vocabulary:
Man, woman, boy,
girl, prince,
princess, queen,
king, monarch




	Femininity	Youth	Royalty
Man	0	0	0
Woman	1	0	0
Boy	0	1	0
Girl	1	1	0
Prince	0	1	1
Princess	1	1	1
Queen	1	0	1
King	0	0	1
Monarch	0.5	0.5	1

Each word gets a
1x3 vector

Similar words...
similar vectors





[Intro to Word Embeddings and
Vectors for Text Analysis.](http://suriyadeepan.github.io/)



VAE

변이 자동 인코더(VAE, Variational autoencoder)

VAE는 압축된 잠재 공간에 데이터를 인코딩한 다음 다시 데이터로 디코딩하는 방법을 학습하는 생성 모델. 이는 특히 입력 데이터의 변형을 생성하는 데 유용.



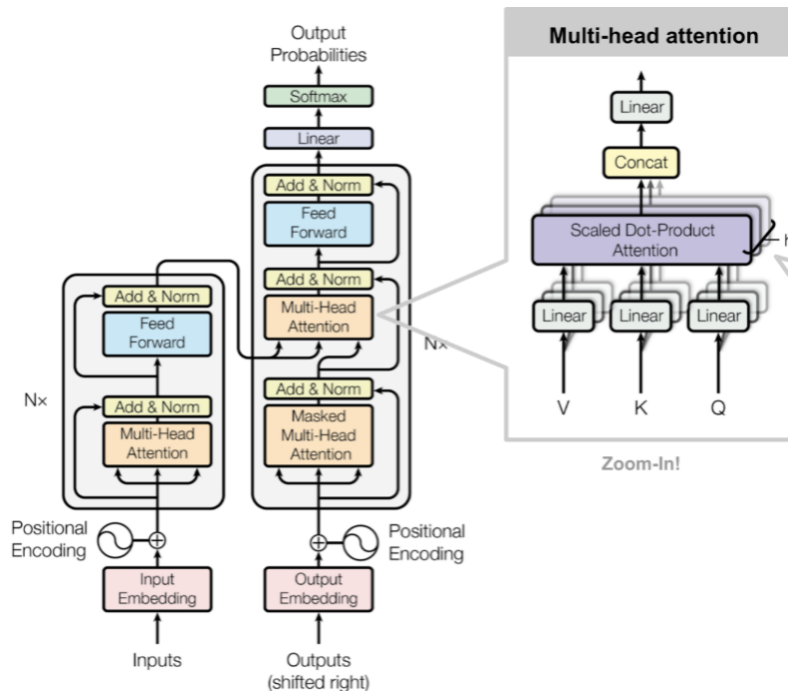
AR-VAE: Attribute-based Regularization of VAE Latent Spaces | Music Informatics Group

The Latent Space |
Bogdan Penkovsky,
PhD

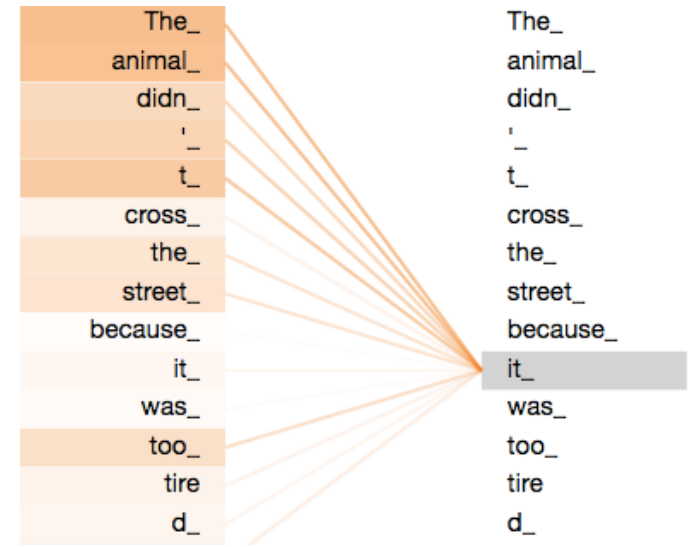
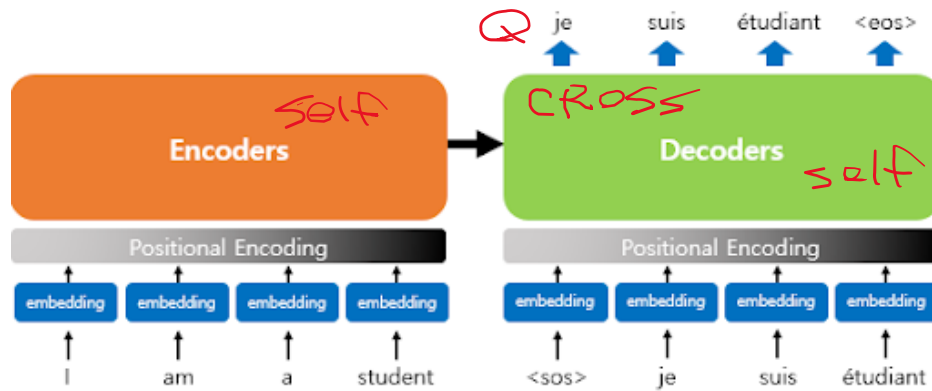
Transformers

변환기(Transformers)


텍스트 생성 영역에서 GPT(Generative Pre-trained Transformer)와 같은 변환기 기반 모델은 방대한 양의 텍스트 데이터에서 어텐션(Attention)계산을 통해 패턴을 학습. 일관되고 맥락적으로 관련성 있는 토큰 시퀀스 학습 가능. 조건화된 이미지 생성에 사용.



Transformers




Five most popular similarity measures implementation in python - Dataaspirant



$$\text{softmax}\left(\frac{Q \times K^T}{\sqrt{d_k}}\right) V = Z$$

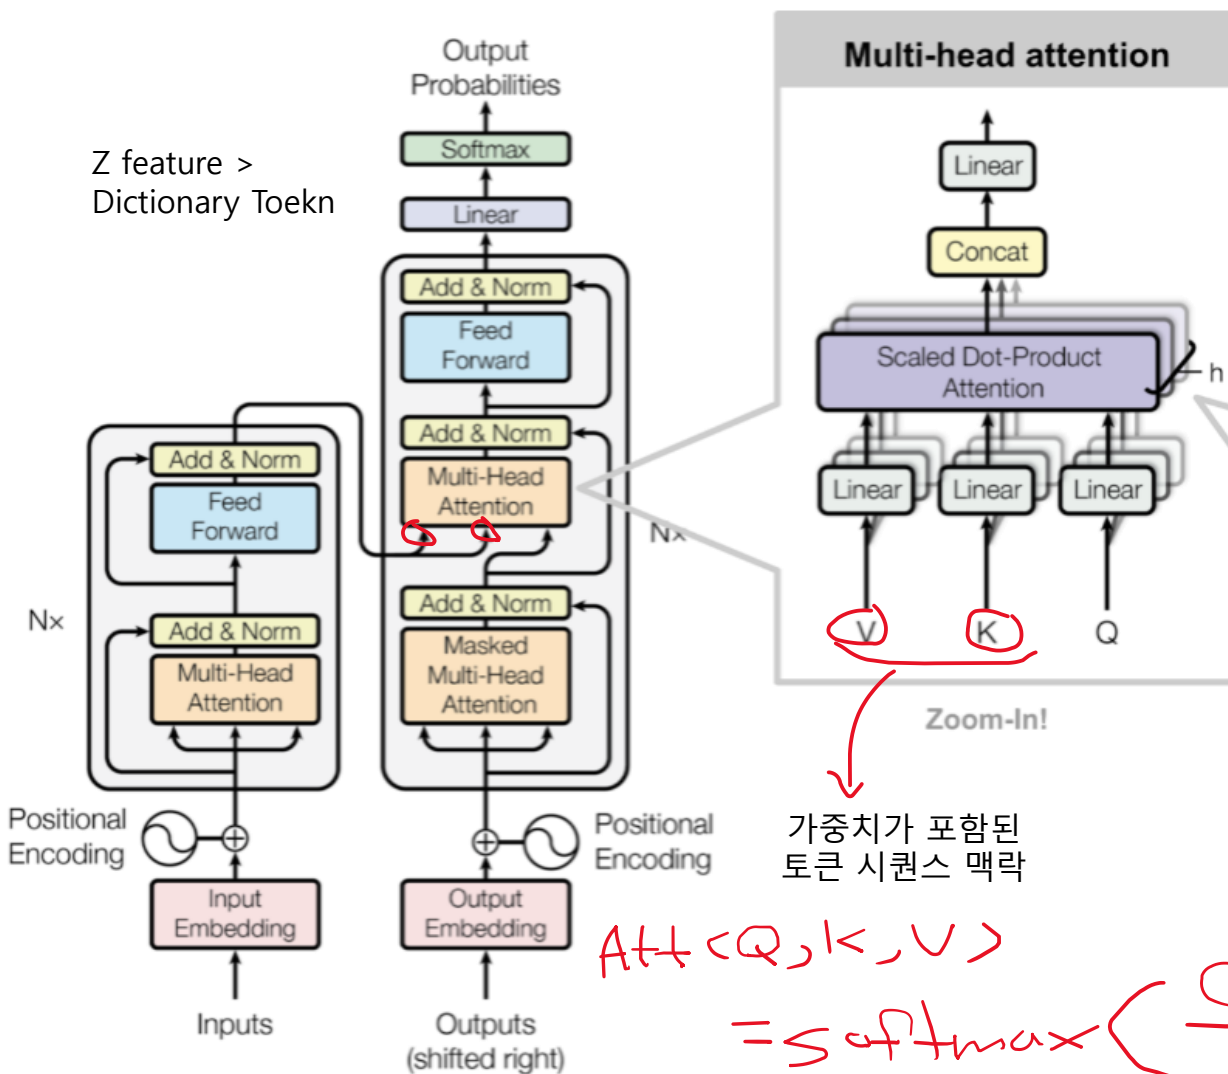
$V \times \text{Softmax}(QK^T)$




Daddy Makers: 딥러닝 모델 트랜스포머 인코더 핵심 코드 구현을 통한 동작 메커니즘 이해하기

Attention & Transformers

Z feature >
Dictionary Token



Self attention
전체를 바라보며 문맥을 통합한
contextual embedding



Self Attention Space

$$Att(Q, K, V)$$


$$= \text{softmax} \left(\frac{Q \cdot K^T}{\sqrt{d_k}} \right) V$$

ex) source code

GAN, VAE, Transformers

"나는 학생" → 어텐션 → out → FFN → logits (10000차원) → softmax → "입니다" (예측)

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$




◆ out	문맥 반영된 벡터 (차원: <code>[seq_len, d_model]</code>)
◆ Feed-Forward Network (FFN)	각 <code>out</code> 벡터를 비선형적으로 변환 (정보 강화)
◆ 디코더 스택 마지막 출력	최종 출력 hidden state
◆ Linear + Softmax	각 hidden state에 대해 전체 vocabulary 크기만큼의 로짓(logits)을 만들 → softmax를 적용해 확률로 변환
◆ 토큰 예측	확률이 가장 높은 단어가 다음 단어로 예측됨 (예: <code>"student"</code> 다음에 <code>"is"</code> 예측 등)

Transformers

- 처음엔 QK^T 가 의미 없는 유사도를 계산함 → softmax 후 V를 평균해서 out 만들
- 이 결과가 **예측 라벨(예: 다음 단어)**과 멀면 loss ↑
- 역전파로 Q, K, V를 만드는 가중치 W_Q, W_K, W_V 가 업데이트됨
- 이 과정이 수천만 문장을 반복하면서 각 Q/K/V가 문맥에서 다른 역할을 하도록 학습됨

역할 = Query Key Value

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$



Transformers

=== 1. 입력 및 라벨 시퀀스 ===

```
input_sentence = ["I", "am", "a", "student"]      # 영어 입력
target_sentence = ["<sos>", "저는", "학생", "입니다"] # 한국어 출력 입력 (디코더 입력)
target_labels = ["저는", "학생", "입니다", "<eos>"]  # 예측할 실제 정답 (디코더 출력)
```

=== 2. 인코더 ===

```
X = embed(input_sentence)      # 입력 시퀀스 임베딩 → [x_I, x_am, x_a, x_student]
```

```
Q_enc = linear_Q(X)           # Q from encoder input
K_enc = linear_K(X)           # K from encoder input
V_enc = linear_V(X)           # V from encoder input
```

```
encoder_outputs = self_attention(Q_enc, K_enc, V_enc) # 인코더 출력: 입력 문맥이 반영된 벡터들
```

Transformers

```
# === 3. 디코더 ===

Y = ["<sos>"]
logits_sequence = []

# 디코더 초기 입력 (<sos> 부터 시작)
# 각 시점의 출력 로짓을 저장

for t in range(len(target_labels)):

    Y_embed = embed(Y) # 현재까지 생성된 디코더 입력 임베딩

    # --- 디코더 Self-Attention (마스킹 포함) ---
    Q_dec = linear_Q_dec(Y_embed) # Q from decoder input
    K_dec = linear_K_dec(Y_embed) # K from decoder input
    V_dec = linear_V_dec(Y_embed) # V from decoder input
    dec_out = masked_self_attention(Q_dec, K_dec, V_dec) # 디코더 내부 문맥 계산 (미래 마스킹 포함)

    # --- Cross-Attention: 디코더 → 인코더 입력 참조 ---
    Q_cross = linear_Q_cross(dec_out) # Q from 디코더 문맥
    K_cross = linear_K_cross(encoder_outputs) # K from 인코더 출력
    V_cross = linear_V_cross(encoder_outputs) # V from 인코더 출력
    cross_out = attention(Q_cross, K_cross, V_cross) # 입력 문장 정보에 기반한 번역 벡터

    # --- 출력 로짓 생성 ---
    logits = linear_output(cross_out) # vocab 크기의 예측 로짓
    logits_sequence.append(logits[-1]) # 마지막 위치 로짓만 저장 (가장 최근 토큰 예측)

    # --- 다음 디코더 입력을 위해 정답을 넣음 (teacher forcing) ---
    next_token = target_sentence[t + 1] # 예: "저는" 다음은 "학생"
    Y.append(next_token) # 다음 루프를 위한 디코더 입력에 추가
```

Transformers




=== 4. 손실(Loss) 계산 ===

```
loss = 0
for logit, label_token in zip(logits_sequence, target_labels):
    label_id = vocab_id(label_token)          # 정답 토큰을 ID로 변환
    loss += cross_entropy_loss(logit, label_id)  # 예측 분포와 정답 ID 간의 CrossEntropy Loss

loss = loss / len(target_labels)             # 평균 손실값 (시퀀스 길이만큼 나눔)

# === 역전파 및 파라미터 업데이트는 이 이후 단계 ===
```

Train and Dataset

instruction string · lengths 	input string · lengths 	output string · lengths 
Find the most frequently used word in the given paragraph.	The cat is black, the dog is brown and the cow is white.	The: 3 times.
Generate a regex pattern to match the following string	String: "Hello123"	\w{5}[0-9]{3}
Write a code snippet to update the value of an element in an array.	Array: {3, 2, 5, 7, 8, 1} Index: 3 New value: 6	array[3] = 6;
Predict a label for the given sentence.	The phone is red .	Label: Color.
Print out the 5th element of an array.	arr = [55, 32, 10, 11, 8]	print(arr[4])
Classify the following text into two categories: 'Sports' and...	The critically acclaimed film 'Avatar' is about a paraplegic Marine who embark...	Entertainment
Create a formula in Excel to calculate the total cost given the price, tax,...	Price: 10 Tax: 0.08 Shipping: 6	=10+0.08*10+6
Classify the following given expression. Your response should be...	x = 0.5	float literal
Classify the following code as either a python function or code section.	x = "hello" z = x + " world"	Code section.
Generate a regex expression to match strings of length 8 with given...	Allowed letters: A-F and digits: 0-9	^[A-F0-9]{8}\$

Train and Dataset

Datasets: junelee/ **sharegpt_deep1_ko** like 53

Dataset card Viewer Files and versions Community

Dataset Preview

API

View in Dataset Viewer

Split (1)

train



► The full dataset viewer is not available (click to read why). Only showing a preview of the rows.

input string	instruction string	output string
	토니 로빈스가 설명하는 인간의 6가지 욕구를 요약해 보세요...	토니 로빈스는 인간의 행동과 동기를 이끄는 6가지 핵심 욕구를 설명합니다. 이 여섯 가지 욕구는 다음과 같습니다: 1. 확실성: 안전, 안정성, 예...
	고객 세그먼트가 잘 세분화되었는지 어떻게 알 수 있을까요? 세 가지로 요약할 수 있습니다.	1. 동질성: 세그먼트는 유사한 특성과 행동을 공유하는 고객으로 구성되어야 합니다. 2. 차별성: 세그먼트는 특성 및 행동 측면에서 다른 세그먼트...
	n Java에서 "이것은 {장소}에 있는 새로운 {객체}입니다"와 같은 문자열을 맵, {객체: "학생", "지점 3, 4"}로 바꾸고 "이 학생은 지점 3, 4...	을 사용하여 문자열의 자리 표시자를 맵의 값으로 바꿀 수 있습니다. 다음은 이를 수행하는 방법을 보여주는 코드 스니펫 예시입니다. ``java...
	전체 단락을 이와 같은 스타일로 작성하세요: 신들의 은총으로 은유적 언어의 신비롭고 수수께끼 같은 예술이 소환되어 우리 앞에 놓인 지침의 당혹...	보세요! 신성한 개입의 은총으로, 이해할 수 없고 불가사의한 은유적 언어의 예술이 우리 앞에 놓인 지침의 불가해한 전달 방식을 해명하기 위해 호...
	길이를 변경할 수 없습니다.	지식의 구도자 여러분, 잠시만요, 우리 앞에 제시된 지침의 복잡한 전달 방식을 설명하는 데 사용된 은유적 언어의 난해하고 수수께끼 같은 예술에 ...
	계속	은유적 언어의 사용은 단순히 보이는 이 지침에도 신비감과 초월성을 불어넣어 줍니다. 특히 '회상하다'라는 단어는 이 지침에 숨겨진 지식이나 비밀...
	다음과 같은 C++ 함수가 있습니다: void add_player(벡터& 플레이어)	주어진 C++ 함수의 'dummy' 변수는 'cin' 문을 사용하여

How to work and use it